

Міністерство освіти і науки України
Національний університет «Запорізька політехніка»

Кафедра програмних засобів

ЗВІТ

Дисципліна «Інтелектуальний аналіз даних»

Робота №2

Тема «Основи попередньої обробки даних»

Виконав варіант 19

Студент КНТ-122

Онищенко О.А.

Прийняли

Викладач

Андрєєв М.О.

2025

МЕТА

Метою роботи є ознайомитися та тримати навички роботи з програмою WEKA бібліотеками мови програмування Python для проведення аналізу даних. На практиці вивчити методи попередньої обробки даних для задач інтелектуального аналізу даних.

ЗАВДАННЯ

Завдання на роботу зі сторінки 35:

1. Обрати в додатку В вибірку для аналізу.
2. Виконати попередню обробку даних за допомогою програми WEKA:
 - завантажити вибірку;
 - описати яке практичне завдання вирішується;
 - описати всі атрибути, які характеризують екземпляри вибірки, та їх типи даних;
 - визначити, який атрибут є цільовим, які значення він приймає та скільки екземплярів кожного класу в вибірці;
 - визначити чи є екземпляри з відсутніми значеннями. Якщо такі екземпляри є, то встановити їм відповідні значення використовуючи одну з наведених стратегії поведінки при роботі з пропущеними значеннями;
 - визначити чи є викиди даних;
 - подати дані в графічному вигляді.
3. Виконати попередню обробку даних за допомогою засобів мови програмування Python:

- конвертувати вибрану для аналізу вибірку з ARFF до CSV формату;
 - використовуючи бібліотеку pandas виконати попередню обробку даних (завантажити файл, вивести на екран частину вибірки, для пропущених значень використати одну з наведених стратегій поведінки);
 - використовуючи бібліотеку matplotlib побудувати необхідні графіки для подання даних в графічному вигляді (типи графіків: pie, hist, scatter, bar);
4. Відповісти на 5 контрольних запитань.
 5. Оформити звіт з роботи.

ВИКОНАННЯ

Завантажена вибірка

Вибірку завантажено, деталі на рисунку нижче:




Рисунок 1.1 — Вибірка даних

Яке практичне завдання вирішується

Ця вибірка вирішує задачу бінарної класифікації даних.

Джерело: <https://www.kaggle.com/datasets/ruthgn/bank-marketing-data-set>.

Описати всі атрибути вибірки, їх типи даних

Опис атрибутів вибірки наведено нижче на таблиці.

Таблиця 1.1 — Дані вибірки

Назва атрибуту	Його опис
Age	Вік користувача
Sex	Стать
Region	Буває <i>inner_city</i> або <i>rural</i> або <i>suburban</i> або <i>town</i>
Income	Числове значення прибутку користувача
Married	Чи є користувач одруженим
Children	Кількість дітей
Car	Чи є користувач власником машини
Save_Act	Чи має користувач накопичувальний рахунок
Current_Act	Чи має користувач поточний рахунок
Mortgage	Чи має користувач іпотечний рахунок
Per	Чи придбав користувач PER (Personal Equity Plan) після останнього листування

Джерело:

<http://facweb.cs.depaul.edu/mobasher/classes/ect584/WEKA/preprocess.html>.

**Визначити, який атрибут є цільовим, які значення приймає;
скільки екземплярів кожного класу в вибірці**

Цільовим є атрибут *per*.

Він приймає значення YES або NO.

Для YES є 274 екземпляри, а для класу NO – 326.

Чи є екземпляри з відсутніми значеннями

Для виконання потрібно подивитись на поле *Missing* для кожного атрибуту.

Викидів немає для жодного атрибуту.

Чи є викиди даних

Для цього потрібно застосувати фільтр *InterquartileRange*.

Кількість викидів показується у доданому атрибуті *Outlier*.

Викидів не знайдено.

Дані в графічному вигляді

Для вхідної ознаки Age та вихідної ознаки Per дані виглядають як описано на малюнку нижче:




Рисунок 1.2 — Графічний вигляд даних

ПИТАННЯ

Що таке якість даних? Яка мета підготовки даних до аналізу?

Якість даних це те, наскільки корисними вони є при застосуванні.

Метою підготовки даних до аналізу є форматування їх для зручнішої роботи.

Що таке атрибут та екземпляр вибірки?

Атрибут це властивість даних.

Екземпляр це окремий елемент вибірки.

Який атрибут даних називають цільовим? Що таке значимий та незначимий атрибут?

Цільовим називають такий атрибут, який складно виміряти.

Значимий це такий атрибут, який корисний.

Незначимий це атрибут, який можна пропустити.

Які функції бібліотеки pandas ви знаєте

Важливі методи бібліотеки pandas:

- `read_csv()`: читає дані з файлу .csv;
- `head()`: видає перші n (за замовчуванням 5) рядків;
- `shape()`: передає розмірність DataFrame-у.

Джерело: <https://www.geeksforgeeks.org/pandas/pandas-functions-in-python/>.

Що таке нормалізація даних та для чого вона використовується?

Нормалізація даних це підганяння певної властивості під заданий діапазон (зазвичай $[0,1]$ або $[-1,1]$).

Вона використовується для кращого співставлення даних в різних діапазонах.