

Міністерство освіти і науки України
Національний університет «Запорізька політехніка»

Кафедра програмних засобів

ЗВІТ

Дисципліна «Інтелектуальний аналіз даних»

Робота №2

Тема «Основи попередньої обробки даних»

Виконав варіант 19

Студент КНТ-122

Онищенко О.А.

Прийняли

Викладач

Андрєєв М.О.

2025

МЕТА

Метою роботи є ознайомитися та тримати навички роботи з програмою WEKA бібліотеками мови програмування Python для проведення аналізу даних. На практиці вивчити методи попередньої обробки даних для задач інтелектуального аналізу даних.

ЗАВДАННЯ

Завдання на роботу зі сторінки 35:

1. Обрати в додатку В вибірку для аналізу.
2. Виконати попередню обробку даних за допомогою програми WEKA:
 - завантажити вибірку;
 - описати яке практичне завдання вирішується;
 - описати всі атрибути, які характеризують екземпляри вибірки, та їх типи даних;
 - визначити, який атрибут є цільовим, які значення він приймає та скільки екземплярів кожного класу в вибірці;
 - визначити чи є екземпляри з відсутніми значеннями. Якщо такі екземпляри є, то встановити їм відповідні значення використовуючи одну з наведених стратегії поведінки при роботі з пропущеними значеннями;
 - визначити чи є викиди даних;
 - подати дані в графічному вигляді.
3. Виконати попередню обробку даних за допомогою засобів мови програмування Python:

- конвертувати вибрану для аналізу вибірку з ARFF до CSV формату;
 - використовуючи бібліотеку pandas виконати попередню обробку даних (завантажити файл, вивести на екран частину вибірки, для пропущених значень використати одну з наведених стратегії поведінки);
 - використовуючи бібліотеку matplotlib побудувати необхідні графіки для подання даних в графічному вигляді (типи графіків: pie, hist, scatter, bar);
4. Відповісти на 5 контрольних запитань.
 5. Оформити звіт з роботи.

ВИКОНАННЯ

Вибірку завантажено з репозиторію: [Weka/Weka datasets/breast-cancer.arff at master · tertiarycourses/Weka](https://weka.org/weka-datasets/breast-cancer.arff).

Вибірку конвертовано до CSV вручну, використовуючи інструменти VS Code:

	A	B	C	D	E	F	G	H	I	J
1	age	meno...	tumor-size	inv-nodes	node-caps	deg-malig	breast	breast-quad	irradiat	Class
2	40-49	premeno	15-19	0-2	yes	3	right	left_up	no	recurrence-events
3	50-59	ge40	15-19	0-2	no	1	right	central	no	no-recurrence-events
4	50-59	ge40	35-39	0-2	no	2	left	left_low	no	recurrence-events
5	40-49	premeno	35-39	0-2	yes	3	right	left_low	yes	no-recurrence-events
6	40-49	premeno	30-34	3-5	yes	2	left	right_up	no	recurrence-events
7	50-59	premeno	25-29	3-5	no	2	right	left_up	yes	no-recurrence-events
8	50-59	ge40	40-44	0-2	no	3	left	left_up	no	no-recurrence-events
9	40-49	premeno	10-14	0-2	no	2	left	left_up	no	no-recurrence-events
10	40-49	premeno	0-4	0-2	no	2	right	right_low	no	no-recurrence-events
11	40-49	ge40	40-44	15-17	yes	2	right	left_up	yes	no-recurrence-events
12	50-59	premeno	25-29	0-2	no	2	left	left_low	no	no-recurrence-events
13	60-69	ge40	15-19	0-2	no	2	right	left_up	no	no-recurrence-events
14	50-59	ge40	30-34	0-2	no	1	right	central	no	no-recurrence-events

Рисунок 1.1 — Вибірка у форматі таблиці

Після запуску коду отримано такі графіки:




Рисунок 1.2 — Графік bar




Рисунок 1.3 — Графік hist




Рисунок 1.4 — Графік pie




Рисунок 1.5 — Графік hist

Код

```
import os
import pandas as pd
from matplotlib import pyplot as plt

# Load data
root_folder = os.path.dirname(os.path.abspath(__file__))
file_name = "breast-cancer.csv"
file_path = os.path.join(root_folder, "data", file_name)

# Print table
data = pd.read_csv(file_path, na_values=["?"])
print(data.head())
print()

# Fill missing values
data["node-caps"] = data["node-caps"].fillna(data["node-caps"].mode())
print(data.head())

# Replace categorical with numbers
data["node-caps"].replace({"yes": 1, "no": 0}, inplace=True)
data["breast"].replace({"left": 1, "right": 0}, inplace=True)
data["irradiat"].replace({"yes": 1, "no": 0}, inplace=True)
print(data.head())

# Pie
data.head().plot(kind="pie", y="deg-malig")
# Hist
data.hist(column="deg-malig")
# Scatter
data.plot(kind="scatter", x="age", y="tumor-size")
# Bar
data.head().plot(kind="bar", y="deg-malig")
plt.show()
```

ПИТАННЯ

Що таке якість даних? Яка мета підготовки даних до аналізу?

Якість даних це те, наскільки корисними вони є при застосуванні.

Метою підготовки даних до аналізу є форматування їх для зручнішої роботи.

Що таке атрибут та екземпляр вибірки?

Атрибут це властивість даних.

Екземпляр це окремий елемент вибірки.

Який атрибут даних називають цільовим? Що таке значимий та незначимий атрибут?

Цільовим називають такий атрибут, який складно виміряти.

Значимий це такий атрибут, який корисний.

Незначимий це атрибут, який можна пропустити.

Які функції бібліотеки pandas ви знаєте

Важливі методи бібліотеки pandas:

- `read_csv()`: читає дані з файлу .csv;
- `head()`: видає перші n (за замовчуванням 5) рядків;
- `shape()`: передає розмірність DataFrame-у.

Джерело: <https://www.geeksforgeeks.org/pandas/pandas-functions-in-python/>.

Що таке нормалізація даних та для чого вона використовується?

Нормалізація даних це підганяння певної властивості під заданий діапазон (зазвичай $[0,1]$ або $[-1,1]$).

Вона використовується для кращого співставлення даних в різних діапазонах.