

Міністерство освіти і науки України
Національний університет «Запорізька політехніка»

Кафедра програмних засобів

ЗВІТ

Дисципліна «Інтелектуальний аналіз даних»

Робота №3

Тема «Задача класифікації»

Виконав варіант 19

Студент КНТ-122

Онищенко О.А.

Прийняли

Викладач

Андрєєв М.О.

2025

МЕТА

Метою роботи є ознайомитися та отримати навички роботи з програмою WEKA та бібліотеками мови програмування Python для вирішення задачі класифікації. На практиці вивчити роботу алгоритмів класифікації, навчитися інтерпретувати результати їх роботи та вибирати найкращий метод для вирішення поставленого завдання.

ЗАВДАННЯ

Завдання на роботу зі сторінки 35:

1. Вирішити задачу класифікації за допомогою програми WEKA:

- завантажити попередньо оброблену вибірку з лабораторної роботи No 2 (ARFF файл);
- побудувати та оцінити моделі класифікації за допомогою всіх розглянутих в лабораторній роботі алгоритмів в WEKA;
- змінюючи параметри налаштування алгоритмів, досягти найліпшої якості навчання різних класифікаторів;
- порівняти отримані моделі класифікації за допомогою модуля Experimenter.

2. Вирішити задачу класифікації за допомогою засобів мови програмування Python:

- завантажити попередньо оброблену вибірку з лабораторної роботи No 2 (CSV файл);
- побудувати та оцінити моделі класифікації за допомогою всіх розглянутих в лабораторній роботі алгоритмів бібліотеки scikit-learn;

- змінюючи параметри налаштування деяких алгоритмів, досягти найліпшої якості навчання класифікаторів;
 - порівняти отримані моделі класифікації за допомогою графічних засобів бібліотеки matplotlib.
3. Відповісти на 5 контрольних запитань.
 4. Оформити звіт з роботи.

ВИКОНАННЯ

1 Завантажити вибірку з лабораторної роботи 2

Вибірку завантажено, деталі на рисунку нижче:




Рисунок 1.1 — Завантажена вибірка

2 Побудувати та оцінити моделі класифікації

Створені моделі наведено нижче на рисунках:

Weka Explorer

PreprocessClassifyClusterAssociateSelect attributesVisualize

Classifier

ChooseZeroR

Test options

☐ Use training set

☐ Supplied test set

☒ Cross-validation

☐ Percentage split

Set...

Folds10

%66

More options...

(Norm) ExtremeValue

StartStop

Result list (right-click for options)

10:37:38 - rules.ZeroR

Classifier output

=== Run information ===

Scheme: weka.classifiers.rules.ZeroR
Relation: bank-data-final-weka.filters.unsupervised.attribute.InterquartileRange-Rfirst-last-O3.0-E6.0
Instances: 600
Attributes: 13
age
sex
region
income
married
children
car
save_act
current_act
mortgage
pep
Outlier
ExtremeValue
Test mode: 10-fold cross-validation

=== Classifier model (full training set) ===

ZeroR predicts class value: no

Time taken to build model: 0 seconds

=== Stratified cross-validation ===

=== Summary ===

Correctly Classified Instances	600	100	%
Incorrectly Classified Instances	0	0	%
Kappa statistic	1		
Mean absolute error	0.0018		
Root mean squared error	0.0018		
Relative absolute error	100	%	
Root relative squared error	100	%	
Total Number of Instances	600		

=== Detailed Accuracy By Class ===

	TP Rate	FP Rate	Precision	Recall	F-Measure	MCC	ROC Area	PRC Area	Class
	1,000	?	1,000	1,000	1,000	?	?	1,000	no
	?	0,000	?	?	?	?	?	?	yes
Weighted Avg.	1,000	?	1,000	1,000	1,000	?	?	1,000	

=== Confusion Matrix ===

a b <-- classified as

600	0	a = no
0	0	b = yes

Status

OK

Log

x 0

Рисунок 2.1 — Модель Rules.ZeroR

Weka Explorer

PreprocessClassifyClusterAssociateSelect attributesVisualize

Classifier

ChooseOneR -B 6

Test options

Use training set

Supplied test set

Cross-validation

Folds10

Percentage split

%66

More options...

(Norm) ExtremeValue

Start

Stop

Result list (right-click for options)

10:37:38 - rules.ZeroR10:41:39 - rules.OneR

Classifier output

=== Run information ===

Scheme:weka.classifiers.rules.OneR -B 6
Relation:bank-data-final-weka.filters.unsupervised.attribute.InterquartileRange-Rfirst-last-O3.0-E6.0
Instances:600
Attributes:13
age
sex
region
income
married
children
car
save_act
current_act
mortgage
pep
Outlier
ExtremeValue
Test mode:10-fold cross-validation

=== Classifier model (full training set) ===

age:
0_34 -> no
35_51 -> no
52_max -> no
(600/600 instances correct)

Time taken to build model: 0 seconds

=== Stratified cross-validation ===

=== Summary ===

Correctly Classified Instances	600	100	%
Incorrectly Classified Instances	0	0	%
Kappa statistic	1		
Mean absolute error	0		
Root mean squared error	0		
Relative absolute error	0	%	
Root relative squared error	0	%	
Total Number of Instances	600		

=== Detailed Accuracy By Class ===

	TP Rate	FP Rate	Precision	Recall	F-Measure	MCC	ROC Area	PRC Area	Class
	1,000	?	1,000	1,000	1,000	?	?	1,000	no
	?	0,000	?	?	?	?	?	?	yes
Weighted Avg.	1,000	?	1,000	1,000	1,000	?	?	1,000	

=== Confusion Matrix ===

a b <-- classified as

600 0 | a = no

0 0 | b = yes

StatusOK

Log

x 0

Рисунок 2.2 — Модель Rules.OneR

Weka Explorer

Preprocess

Classify

Cluster

Associate

Select attributes

Visualize

Classifier

ChoosePrism

Test options

Use training set

Supplied test set

Cross-validation

Percentage split

Folds

10

%

66

More options...

(Nom) ExtremeValue

Start

Stop

Result list (right-click for options)

10:48:00 - rules.Prism

Classifier output

```

=== Run information ===

Scheme:      weka.classifiers.rules.Prism
Relation:    bank-data-final-weka.filters.unsupervised.attribute.InterquartileRange-Rfirst-last-O3.0-E6.0
Instances:   600
Attributes:  13
              age
              sex
              region
              income
              married
              children
              car
              save_act
              current_act
              mortgage
              pep
              Outlier
              ExtremeValue

Test mode:   10-fold cross-validation

=== Classifier model (full training set) ===

Prism rules
-----
no

Time taken to build model: 0 seconds

=== Stratified cross-validation ===
=== Summary ===

Correctly Classified Instances      600          100    %
Incorrectly Classified Instances    0           0    %
Kappa statistic                    1
Mean absolute error                 0
Root mean squared error             0
Relative absolute error              0    %
Root relative squared error          0    %
Total Number of Instances          600

=== Detailed Accuracy By Class ===

              TP Rate  FP Rate  Precision  Recall   F-Measure  MCC      ROC Area  PRC Area  Class
              1,000   ?        1,000      1,000    1,000      ?        ?        1,000    no
              ?        0,000   ?          ?        ?          ?        ?        ?        yes
Weighted Avg.   1,000   ?        1,000      1,000    1,000      ?        ?        1,000

=== Confusion Matrix ===

  a  b  <-- classified as
600  0 |  a = no
  0  0 |  b = yes

```

Status

OK

Log

x0

Рисунок 2.3 — Модель Rules.Prism

Weka Explorer

Preprocess

Classify

Cluster

Associate

Select attributes

Visualize

Classifier

Choose NaiveBayes

Test options

Use training set

Supplied test set

Cross-validation

Percentage split

Folds

%

10

66

More options...

(Nom) ExtremeValue

Start

Stop

Result list (right-click for options)

10:48:00 - rules.Prism

10:50:30 - bayes.NaiveBayes

Classifier output

[total]

602.0

2.0

save_act

NO

187.0

1.0

YES

415.0

1.0

[total]

602.0

2.0

current_act

NO

146.0

1.0

YES

456.0

1.0

[total]

602.0

2.0

mortgage

NO

392.0

1.0

YES

210.0

1.0

[total]

602.0

2.0

pep

YES

275.0

1.0

NO

327.0

1.0

[total]

602.0

2.0

Outlier

no

601.0

1.0

yes

1.0

1.0

[total]

602.0

2.0

Time taken to build model: 0 seconds

=== Stratified cross-validation ===

=== Summary ===

Correctly Classified Instances

600

100

%

Incorrectly Classified Instances

0

0

%

Kappa statistic

1

Mean absolute error

0.0009

Root mean squared error

0.0019

Relative absolute error

50.6564 %

Root relative squared error

104.4317 %

Total Number of Instances

600

=== Detailed Accuracy By Class ===

TP Rate

FP Rate

Precision

Recall

F-Measure

MCC

ROC Area

PRC Area

Class

1,000

?

1,000

1,000

1,000

?

?

1,000

no

?

0,000

?

?

?

?

?

?

yes

Weighted Avg.

1,000

?

1,000

1,000

1,000

?

1,000

=== Confusion Matrix ===

a

b

<-- classified as

600

0

|

a = no

0

0

|

b = yes

Status

OK

Log

x0

Рисунок 2.4 — Модель Bayes.NaiveBayes

Weka Explorer

Preprocess

Classify

Cluster

Associate

Select attributes

Visualize

Classifier

Choose J48 -C 0.25 -M 2

Test options

Use training set

Supplied test set

Cross-validation

Percentage split

Folds

10

%

66

More options...

(Nom) ExtremeValue

Start

Stop

Result list (right-click for options)

10:52:47 - lazy.IBk

11:01:10 - trees.J48

Classifier output

=== Run information ===

Scheme:

weka.classifiers.trees.J48 -C 0.25 -M 2

Relation:

bank-data-final-weka.filters.unsupervised.attribute.InterquartileRange-Rfirst-last-O3.0-E6.0

Instances:

600

Attributes:

13

age

sex

region

income

married

children

car

save_act

current_act

mortgage

pep

Outlier

ExtremeValue

Test mode:

10-fold cross-validation

=== Classifier model (full training set) ===

J48 pruned tree

: no (600.0)

Number of Leaves : 1

Size of the tree : 1

Time taken to build model: 0 seconds

=== Stratified cross-validation ===

=== Summary ===

Correctly Classified Instances

600

100

%

Incorrectly Classified Instances

0

0

%

Kappa statistic

1

Mean absolute error

0

Root mean squared error

0

Relative absolute error

0

%

Root relative squared error

0

%

Total Number of Instances

600

=== Detailed Accuracy By Class ===

TP Rate

FP Rate

Precision

Recall

F-Measure

MCC

ROC Area

PRC Area

Class

1,000

?

1,000

1,000

1,000

?

?

1,000

no

?

0,000

?

?

?

?

?

?

yes

Weighted Avg.

1,000

?

1,000

1,000

1,000

?

?

1,000

=== Confusion Matrix ===

a

b

<-- classified as

600

0

|

a = no

0

0

|

b = yes

Status

OK

Log

x 0

Рисунок 2.5 — Модель Trees.J48

Weka Explorer

Preprocess

Classify

Cluster

Associate

Select attributes

Visualize

Classifier

Choose

SMO -C 1.0 -L 0.001 -P 1.0E-12 -N 0 -V -1 -W 1 -K "weka.classifiers.functions.supportVector.PolyKernel -E 1.0 -C 250007" -calibrator "weka.classifiers.functions.Logistic -R 1.0E-8 -M -1

Test options

Use training set

Supplied test set

Cross-validation

Percentage split

Folds

10

%

66

More options...

(Nom) ExtremeValue

Start

Stop

Result list (right-click for options)

10:52:47 - lazy.IBk

11:01:10 - trees.J48

11:02:23 - functions.SMO

Classifier output

=== Run information ===

Scheme:

weka.classifiers.functions.SMO -C 1.0 -L 0.001 -P 1.0E-12 -N 0 -V -1 -W 1 -K "weka.classifiers

Relation:

bank-data-final-weka.filters.unsupervised.attribute.InterquartileRange-Rfirst-last-O3.0-E6.0

Instances:

600

Attributes:

13

age

sex

region

income

married

children

car

save_act

current_act

mortgage

pep

Outlier

ExtremeValue

Test mode:

10-fold cross-validation

=== Classifier model (full training set) ===

SMO

Kernel used:

Linear Kernel: $K(x,y) = \langle x,y \rangle$

Classifier for classes: no, yes

BinarySMO

Machine linear: showing attribute weights, not support vectors.

- 1

Number of kernel evaluations: -1

Time taken to build model: 0.01 seconds

=== Stratified cross-validation ===

=== Summary ===

Correctly Classified Instances	600	100	%
Incorrectly Classified Instances	0	0	%
Kappa statistic	1		
Mean absolute error	0		
Root mean squared error	0		
Relative absolute error	0	%	
Root relative squared error	0	%	
Total Number of Instances	600		

=== Detailed Accuracy By Class ===

	TP Rate	FP Rate	Precision	Recall	F-Measure	MCC	ROC Area	PRC Area	Class
	1,000	?	1,000	1,000	1,000	?	?	1,000	no
	?	0,000	?	?	?	?	?	?	yes
Weighted Avg.	1,000	?	1,000	1,000	1,000	?	?	1,000	

=== Confusion Matrix ===

a

b

<-- classified as

600

0

|

a = no

0

0

|

b = yes

Status

OK

Log

x 0

Рисунок 2.6 — Модель Functions.SMO




Рисунок 2.7 — Модель Lazy.IBk

3 Досягти найліпшої якості навчання різних класифікаторів

Після початкового використання методів було досягнуто таку кількість правильних відповідей для кожного методу:

Таблиця 1.1 — Кількості правильних відповідей

№	Метод	Кількість правильних відповідей
1	Rules.ZeroR	600
2	Rules.OneR	600
3	Rules.Prism	600
4	Bayes.NaiveBayes	600
5	Trees.J48	600
6	Functions.SMO	600
7	Lazy.IBk	600

3.2 Rules.OneR

При встановленні Min Bucket Size у 3 все одно результат максимальний — 600 правильно визначених екземплярів.

Деталі на рисунку нижче:




Рисунок 3.1 — Результати зі зміненими параметрами

3.6 *Trees.J48*

Встановивши параметри:

- confidenceFactor – 0.3;
- minNumObj – 1.

Отримано такі результати, деталі на рисунку:

The screenshot shows the Weka Explorer interface with the 'Classify' tab selected. The classifier chosen is 'J48 -C 0.3 -M 1'. The 'Test options' section shows 'Cross-validation' selected with 'Folds' set to 10. The 'Result list' on the left shows a list of recent operations, with '11:15:14 - trees.J48' selected. The 'Classifier output' pane displays the following results:

```
Time taken to build model: 0 seconds

=== Stratified cross-validation ===
=== Summary ===

Correctly Classified Instances      600           100   %
Incorrectly Classified Instances    0           0   %
Kappa statistic                     1
Mean absolute error                  0
Root mean squared error              0
Relative absolute error              0   %
Root relative squared error          0   %
Total Number of Instances          600

=== Detailed Accuracy By Class ===

               TP Rate  FP Rate  Precision  Recall   F-Measure  MCC      ROC Area  PRC Area  Class
               1,000   ?        1,000     1,000    1,000     ?        ?        1,000    no
               ?        0,000   ?         ?         ?         ?        ?        ?        yes
Weighted Avg.   1,000   ?        1,000     1,000    1,000     ?        ?        1,000

=== Confusion Matrix ===

  a  b  <-- classified as
600  0  |  a = no
  0  0  |  b = yes
```

The status bar at the bottom shows 'Status OK' and a 'Log' button.

Рисунок 3.2 — Модель при виконанні

3.7 *Functions.SMO*

Встановивши параметри:

- c: 3.0;
- toleranceParameter: 0.1.

Отримано такі результати:

Classifier

Choose **SMO** -C 3.0 -L 0.1 -P 1.0E-12 -N 0 -V -1 -W 1 -K "weka.classifiers.functions.supportVector.PolyKernel -E 1.0 -C 250007" -calibrator "weka.classifiers.functions.Logistic -R 1.0E-8"

Test options

☐ Use training set

☐ Supplied test set

☒ Cross-validation Folds

☐ Percentage split %

(Nom) ExtremeValue

Result list (right-click for options)

- 11:06:23 - rules.ZeroR
- 11:09:54 - rules.OneR
- 11:11:58 - rules.OneR
- 11:14:52 - trees.J48
- 11:15:14 - trees.J48
- 11:16:36 - functions.SMO
- 11:51:36 - functions.SMO**

Classifier output

Time taken to build model: 0 seconds

=== Stratified cross-validation ===

=== Summary ===

Correctly Classified Instances	600	100	%
Incorrectly Classified Instances	0	0	%
Kappa statistic	1		
Mean absolute error	0		
Root mean squared error	0		
Relative absolute error	0	%	
Root relative squared error	0	%	
Total Number of Instances	600		

=== Detailed Accuracy By Class ===

	TP Rate	FP Rate	Precision	Recall	F-Measure	MCC	ROC Area	PRC Area	Class
	1,000	?	1,000	1,000	1,000	?	?	1,000	no
	?	0,000	?	?	?	?	?	?	yes
Weighted Avg.	1,000	?	1,000	1,000	1,000	?	?	1,000	

=== Confusion Matrix ===

```

a  b  <-- classified as
600  0 | a = no
  0  0 | b = yes

```

Status
OK

 x 0

Рисунок 3.3 — Модель після виконання

3.8 Lazy.IBk

Змінивши такі параметри:

- KNN – 5;
- windowSize – 5.

Отримано такі результати:




Рисунок 3.4 — Модель при виконанні

4 Порівняти отримані моделі через модуль Experimenter

Моделі до вікна Experimenter додано:




Рисунок 4.1 — Додані моделі

Після цього було запущено тести:




Рисунок 4.2 — Запущені тести

ВИСНОВКИ

Благодаттю Господа Ісуса Христа було зроблено роботу.

ПИТАННЯ

Що таке задача класифікації? Наведіть практичний приклад.

Задача класифікації — це надання елементам вибірки класи, за якими їх можна розпізнати.

Приклад: віднести картинки до групок зі своїм класом (тварин, скажімо).

Що таке навчання з учителем і без учителя? До якої стратегії відноситься задача класифікації?

Навчання з учителем це коли для моделі є вихідна ознака, а без учителя це коли її немає.

Класифікація відноситься до навчання з учителем.

Які алгоритми класифікації ви знаєте?

Відомі такі алгоритми класифікації:

- KNearestNeighbors;
- SVM;
- Decision Tree.

Опишіть один із методів класифікації.

SVM працює шляхом віднайдення такої гіперплощини, яка б розділяла кластери, максимізуючи відстані між ними.

Навіщо потрібні дві вибірки: навчальна і тестова? Які існують підходи для поділу вихідної вибірки на навчальну і тестову?

Це потрібно, аби уникнути перенавчання.

Розбити на навчальну і розпізнавальну вибірки можна або методом `train_test_split`, або методом `KFold`.