

Міністерство освіти і науки України
Національний університет «Запорізька політехніка»

Кафедра програмних засобів

ЗВІТ

Дисципліна «Інтелектуальний аналіз даних»

Робота №3

Тема «Задача класифікації»

Виконав варіант 19

Студент КНТ-122

Онищенко О.А.

Прийняли

Викладач

Андрєєв М.О.

2025

МЕТА

Метою роботи є ознайомитися та отримати навички роботи з програмою WEKA та бібліотеками мови програмування Python для вирішення задачі класифікації. На практиці вивчити роботу алгоритмів класифікації, навчитися інтерпретувати результати їх роботи та вибирати найкращий метод для вирішення поставленого завдання.

ЗАВДАННЯ

Завдання на роботу зі сторінки 35:

1. Вирішити задачу класифікації за допомогою програми WEKA:
 - завантажити попередньо оброблену вибірку з лабораторної роботи No 2 (ARFF файл);
 - побудувати та оцінити моделі класифікації за допомогою всіх розглянутих в лабораторній роботі алгоритмів в WEKA;
 - змінюючи параметри налаштування алгоритмів, досягти найліпшої якості навчання різних класифікаторів;
 - порівняти отримані моделі класифікації за допомогою модуля Experimenter.
2. Вирішити задачу класифікації за допомогою засобів мови програмування Python:
 - завантажити попередньо оброблену вибірку з лабораторної роботи No 2 (CSV файл);
 - побудувати та оцінити моделі класифікації за допомогою всіх розглянутих в лабораторній роботі алгоритмів бібліотеки scikit-learn;

- змінюючи параметри налаштування деяких алгоритмів, досягти найліпшої якості навчання класифікаторів;
 - порівняти отримані моделі класифікації за допомогою графічних засобів бібліотеки `matplotlib`.
3. Відповісти на 5 контрольних запитань.
 4. Оформити звіт з роботи.

Виконання

Розробку моделей наведено нижче на рисунках:




Рисунок 1.1 — Модель ZeroR

Weka Explorer

Preprocess

Classify

Cluster

Associate

Select attributes

Visualize

Classifier

Choose OneR -B 6

Test options

☒ Use training set
☐ Supplied test set

☐ Cross-validation
 10

☐ Percentage split
 66

(Nom) class

Result list (right-click for options)

16:53:30 - functions.SMO

16:54:48 - functions.SMO

16:54:54 - functions.SMO

16:55:04 - functions.SMO

16:57:20 - rules.ZeroR

17:01:29 - rules.OneR

Classifier output

< 0.8 -> Iris-setosa

< 1.75 -> Iris-versicolor

>= 1.75 -> Iris-virginica

(144/150 instances correct)

Time taken to build model: 0 seconds

=== Evaluation on training set ===

Time taken to test model on training data: 0 seconds

=== Summary ===

Correctly Classified Instances	144	96	%
Incorrectly Classified Instances	6	4	%
Kappa statistic	0.94		
Mean absolute error	0.0267		
Root mean squared error	0.1633		
Relative absolute error	6	%	
Root relative squared error	34.641	%	
Total Number of Instances	150		

=== Detailed Accuracy By Class ===

	TP Rate	FP Rate	Precision	Recall	F-Measure	MCC
1,000	0,000	1,000	1,000	1,000	1,000	
0,980	0,050	0,907	0,980	0,942	0,913	
0,900	0,010	0,978	0,900	0,938	0,910	
Weighted Avg.	0,960	0,020	0,962	0,960	0,960	0,941

=== Confusion Matrix ===

a b c <-- classified as

50 0 0 | a = Iris-setosa

0 49 1 | b = Iris-versicolor

0 5 45 | c = Iris-virginica

Status

OK

x 0

Рисунок 1.2 — Модель OneR

Weka Explorer

Preprocess

Classify

Cluster

Associate

Select attributes

Visualize

Classifier

Choose NaiveBayes

Test options

Use training set

Supplied test set

Cross-validation

Percentage split

Set...

Folds 10

% 66

More options...

(Nom) class

Start

Stop

Result list (right-click for options)

16:53:30 - functions.SMO

16:54:48 - functions.SMO

16:54:54 - functions.SMO

16:55:04 - functions.SMO

16:57:20 - rules.ZeroR

17:01:29 - rules.OneR

17:02:43 - bayes.NaiveBayes

Classifier output

std. dev.

weight sum

precision

0.1096

0.1915

0.2646

50

50

50

0.1143

0.1143

0.1143

Time taken to build model: 0.01 seconds

=== Evaluation on training set ===

Time taken to test model on training data: 0 seconds

=== Summary ===

Correctly Classified Instances

Incorrectly Classified Instances

Kappa statistic

Mean absolute error

Root mean squared error

Relative absolute error

Root relative squared error

Total Number of Instances

144

6

0.94

0.0324

0.1495

7.2883 %

31.7089 %

150

=== Detailed Accuracy By Class ===

TP Rate

FP Rate

Precision

Recall

F-Measure

MCC

1,000

0,000

1,000

1,000

1,000

1,000

0,960

0,040

0,923

0,960

0,941

0,911

0,920

0,020

0,958

0,920

0,939

0,910

Weighted Avg.

0,960

0,020

0,960

0,960

0,960

0,940

=== Confusion Matrix ===

a b c <-- classified as

50 0 0 | a = Iris-setosa

0 48 2 | b = Iris-versicolor

0 4 46 | c = Iris-virginica

Status

OK

Log

x 0

Рисунок 1.3 — Модель NaiveBayes

Weka Explorer

Preprocess

Classify

Cluster

Associate

Select attributes

Visualize

Classifier

Choose

J48 -C 0.25 -M 2

Test options

☒ Use training set

☐ Supplied test set

Set...

☐ Cross-validation

Folds

10

☐ Percentage split

%

66

More options...

(Nom) class

Start

Stop

Result list (right-click for options)

16:53:30 - functions.SMO

16:54:48 - functions.SMO

16:54:54 - functions.SMO

16:55:04 - functions.SMO

16:57:20 - rules.ZeroR

17:01:29 - rules.OneR

17:02:43 - bayes.NaiveBayes

17:05:15 - trees.J48

Classifier output

Number of Leaves : 5

Size of the tree : 9

Time taken to build model: 0 seconds

=== Evaluation on training set ===

Time taken to test model on training data: 0 seconds

=== Summary ===

Correctly Classified Instances	147	98	%
Incorrectly Classified Instances	3	2	%
Kappa statistic	0.97		
Mean absolute error	0.0233		
Root mean squared error	0.108		
Relative absolute error	5.2482 %		
Root relative squared error	22.9089 %		
Total Number of Instances	150		

=== Detailed Accuracy By Class ===

	TP Rate	FP Rate	Precision	Recall	F-Measure	MCC
1,000	0,000	1,000	1,000	1,000	1,000	1,000
0,980	0,020	0,961	0,980	0,970	0,955	
0,960	0,010	0,980	0,960	0,970	0,955	
Weighted Avg.	0,980	0,010	0,980	0,980	0,980	0,970

=== Confusion Matrix ===

a b c <-- classified as

50 0 0 | a = Iris-setosa

0 49 1 | b = Iris-versicolor

0 2 48 | c = Iris-virginica

Status

OK

Log

x 0

Рисунок 1.4 — Модель J48

Weka Explorer

Preprocess

Classify

Cluster

Associate

Select attributes

Visualize

Classifier

Choose

SMO -C 1.0 -L 0.001 -P 1.0E-12 -N 0 -V -1 -W 1 -K "weka.classifiers.functions.supportVector.PolyKernel -E 1.0 -C 250007" -calibrator "w

Test options

Use training set

Supplied test set

Cross-validation

Percentage split

Set...

Folds

%

10

66

More options...

(Nom) class

Start

Stop

Result list (right-click for options)

16:53:30 - functions.SMO

16:54:48 - functions.SMO

16:54:54 - functions.SMO

16:55:04 - functions.SMO

16:57:20 - rules.ZeroR

17:01:29 - rules.OneR

17:02:43 - bayes.NaiveBayes

17:05:15 - trees.J48

17:06:05 - functions.SMO

Classifier output

- 4.5924

Number of kernel evaluations: 453 (61.381% cached)

Time taken to build model: 0.02 seconds

=== Evaluation on training set ===

Time taken to test model on training data: 0 seconds

=== Summary ===

Correctly Classified Instances	145	96.6667 %
Incorrectly Classified Instances	5	3.3333 %
Kappa statistic	0.95	
Mean absolute error	0.2296	
Root mean squared error	0.2854	
Relative absolute error	51.6667 %	
Root relative squared error	60.553 %	
Total Number of Instances	150	

=== Detailed Accuracy By Class ===

	TP Rate	FP Rate	Precision	Recall	F-Measure	MCC
	1,000	0,000	1,000	1,000	1,000	1,000
	0,980	0,040	0,925	0,980	0,951	0,927
	0,920	0,010	0,979	0,920	0,948	0,925
Weighted Avg.	0,967	0,017	0,968	0,967	0,967	0,951

=== Confusion Matrix ===

a b c <-- classified as

50 0 0 | a = Iris-setosa

0 49 1 | b = Iris-versicolor

0 4 46 | c = Iris-virginica

Status

OK

Log

x 0

Рисунок 1.5 — Модель SMO




Рисунок 1.6 — Модель IBk

Порівняння




Рисунок 2.1 — Порівняння моделей

ПИТАННЯ

Що таке задача класифікації? Наведіть практичний приклад.

Задача класифікації — це надання елементам вибірки класи, за якими їх можна розпізнати.

Приклад: віднести картинки до групок зі своїм класом (тварин, скажімо).

Що таке навчання з учителем і без учителя? До якої стратегії відноситься задача класифікації?

Навчання з учителем це коли для моделі є вихідна ознака, а без учителя це коли її немає.

Класифікація відноситься до навчання з учителем.

Які алгоритми класифікації ви знаєте?

Відомі такі алгоритми класифікації:

- KNearestNeighbors;
- SVM;
- Decision Tree.

Опишіть один із методів класифікації.

SVM працює шляхом віднайдення такої гіперплощини, яка б розділяла кластери, максимізуючи відстані між ними.

Навіщо потрібні дві вибірки: навчальна і тестова? Які існують підходи для поділу вихідної вибірки на навчальну і тестову?

Це потрібно, аби уникнути перенавчання.

Розбити на навчальну і розпізнавальну вибірки можна або методом `train_test_split`, або методом `KFold`.