

Міністерство освіти і науки України
Національний університет «Запорізька політехніка»

Кафедра програмних засобів

ЗВІТ

Дисципліна «Інтелектуальний аналіз даних»

Робота №4

Тема «Прогнозування, задача регресії»

Виконав варіант 19

Студент КНТ-122

Онищенко О.А.

Прийняли

Викладач

Андрєєв М.О.

2025

МЕТА

Метою роботи є ознайомитися та отримати навички роботи з програмою WEKA та бібліотеками мови програмування Python для прогнозування та вирішення задачі регресії. На практиці вивчити роботу алгоритмів, що вирішують задачу регресії, навчитися інтерпретувати результати їх роботи та вибирати найкращий метод для вирішення поставленого завдання.

ЗАВДАННЯ

Завдання на роботу зі сторінки 35:

1. Обрати в додатку В вибірку для регресійного аналізу. Конвертувати та, якщо необхідно, виконати попередню обробку даних.
2. Вирішити задачу регресії за допомогою програми WEKA:
 - завантажити вибірку (ARFF файл);
 - побудувати та оцінити моделі регресії за допомогою всіх розглянутих в лабораторній роботі алгоритмів в WEKA;
 - для метода M5P (model trees and regression trees) змінюючи параметри build regression tree, unpruned, useUnsmoothed досягти найліпшої якості прогнозування;
 - навести одну з отриманих регресійних моделей (рівняння регресії) та визначити які з атрибутів є найбільш значущими (на основі отриманих коефіцієнтів рівняння регресії) для прогнозування значень;
 - порівняти отримані моделі регресії за допомогою модуля Experimenter.

3. Вирішити задачу регресії за допомогою засобів мови програмування Python:
- завантажити вибірку (CSV файл);
 - побудувати та оцінити моделі регресії за допомогою всіх розглянутих в лабораторній роботі алгоритмів бібліотеки `scikit-learn`;
 - змінюючи параметри налаштування деяких алгоритмів, досягти найліпшої якості прогнозування;
 - визначити які з атрибутів є найбільш значущими (на основі отриманих коефіцієнтів рівняння регресії) для прогнозування значень цільового атрибута;
 - порівняти отримані регресійні моделі та значимість атрибутів за допомогою графічних засобів бібліотеки `matplotlib`.
4. Відповісти на 5 контрольних запитань.
5. Оформити звіт з роботи.

Виконання

Вибірку “`cru.arff`” було завантажено.

Моделі

Побудовані моделі наведено нижче на рисунках:

1 Functions.LinearRegression




Рисунок 1.1 — Модель Linear Regression




Рисунок 1.2 — Візуалізація помилок

2 Trees.M5P

Weka Explorer

Preprocess

Classify

Cluster

Associate

Select attributes

Visualize

Classifier

Choose

M5P -M 4.0 -num-decimal-places 4

Test options

☐ Use training set
 ☐ Supplied test set

Set...

☒ Cross-validation

Folds

10

☐ Percentage split

%

66

More options...

(Num) class

Start

Stop

Result list (right-click for options)

16:20:23 - functions.LinearRegression

16:41:18 - trees.M5P

Classifier output

Relation: cpu

Instances: 209

Attributes: 7

MYCT

MMIN

MMAX

CACH

CHMIN

CHMAX

class

Test mode: 10-fold cross-validation

=== Classifier model (full training set) ===

M5 pruned model tree:

(using smoothed linear models)

MMAX <= 14000 : LM1 (141/2.365%)

MMAX > 14000 : LM2 (68/31.964%)

LM num: 1

class =

0.0064 * MYCT

+ 0.0014 * MMIN

+ 0.0035 * MMAX

+ 0.5528 * CACH

+ 1.1411 * CHMIN

+ 0.1141 * CHMAX

+ 3.1462

LM num: 2

class =

0.012 * MYCT

+ 0.0133 * MMIN

+ 0.009 * MMAX

+ 0.7285 * CACH

+ 1.2742 * CHMAX

- 149.9329

Number of Rules : 2

Time taken to build model: 0.02 seconds

=== Cross-validation ===

=== Summary ===

Correlation coefficient

Mean absolute error

Root mean squared error

Relative absolute error

Root relative squared error

Total Number of Instances

0.9751

13.4679

35.1885

15.3641 %

22.7369 %

209

Status

OK

Log

x 0

Рисунок 1.3 — Модель M5P




Рисунок 1.4 — Візуалізація помилок

3 Functions.SMOreg




Рисунок 1.5 — Модель SMOReg




Рисунок 1.6 — Візуалізація помилок

4 Lazy.IBk




Рисунок 1.7 — Модель IBk




Рисунок 1.8 — Візуалізація помилок

Параметри M5P

Змінені параметри M5P, значення `buildRegressionTree`, `unpruned` та `useUnsmoothed` встановлено у `True`. Деталі на рисунках:




Рисунок 2.1 — Параметри моделі




Рисунок 2.2 — Результати роботи

Порівняння

Порівняння моделей наведено на таблиці та рисунках нижче:

Таблиця 1.1 — Порівняння результатів

Модель	Коефіцієнт кореляції
--------	----------------------

Модель	Коефіцієнт кореляції
Functions.LinearRegression	0.92
Trees.M5P	0.97
Functions.SMOreg	0.93
Lazy.IBK	0.95




Рисунок 3.1 — Порівняння моделей

ВИСНОВКИ

Модель M5P впоралася найкраще. Коефіцієнти кореляції було порівняно. Також було продемонстровано візуалізації помилок.

ПИТАННЯ

Що таке задача регресії? Наведіть практичний приклад.

Регресія — це встановлення залежності неперервних вихідних даних до вхідних параметрів.

Відношення площі будинку до його вартості.

В чому схожість та відмінність між задачами регресії та класифікації?

На відміну від задачі класифікації, задача регресії приймає неперервні (а не дискретні, як у класифікації) значення ознак.

Що таке навчання з учителем і без учителя? До якої стратегії відноситься задача регресії?

Навчання з учителем це коли до задачі даються вихідні ознаки; задача навчання без учителя це коли дані лише вхідні ознаки.

Задача регресії відноситься до задачі навчання з учителем.

Які алгоритми побудови моделей регресії ви знаєте?

Деякі з відомих алгоритмів побудови регресії:

- лінійна регресія;
- K-найближчих сусідів;
- дерево рішень.

Опишіть один із методів побудови моделей регресії.

Метод регресії К-найближчих сусідів передбачає значення вихідних ознак як середнє між вихідними ознаками К (зазначається користувачем) найближчих до елемента сусідніх елементів.

Джерело: [GeeksForGeeks](https://www.geeksforgeeks.org/k-nearest-neighbors-classification/).