

Міністерство освіти і науки України
Національний університет «Запорізька політехніка»

Кафедра програмних засобів

ЗВІТ

Дисципліна «Інтелектуальний аналіз даних»

Робота №6

Тема «Програмні засоби кластеризації даних»

Виконав варіант 19

Студент КНТ-122

Онищенко О.А.

Прийняли

Викладач

Андрєєв М.О.

2025

МЕТА

Метою роботи є ознайомитися та отримати навички роботи з програмою WEKA та бібліотеками мови програмування Python для вирішення задачі кластеризації. На практиці вивчити роботу алгоритмів кластеризації, навчитися інтерпретувати результати їх роботи та вибирати найкращий метод для розв'язуваної прикладної задач.

ЗАВДАННЯ

Завдання на роботу зі сторінки 35:

1. Вирішити задачу кластеризації за допомогою програми WEKA завантажити вибірку «bank.arff»;

- запустити алгоритм кластеризації SimpleKMeans, задаючи значення параметра K (кількість кластерів) від 1 до 12;

- записати в таблицю значення сум квадратичних помилок, одержуваних при різних значеннях. Проаналізувати результат;

- для значення $K = 5$ візуалізувати результати кластеризації (по осі абсцис відкласти назву (номер) кластера, по осі ординат – номер примірника в кластері);

- описати скільки примірників потрапило в кожен із кластерів, скільки ітерацій знадобилося для кластеризації даних;

- скласти таблицю з характеристиками центроїдів;

- завантажити вибірку «iris.arff»;

- запустити алгоритм кластеризації SimpleKMeans з $K = 3$ та оцінити якість кластеризації, порівнюючи кластери з попередньо заданими класами;

- записати характеристики кожного центроїду;

- описати як співвідносяться кластери та значення цільового атрибуту, скільки екземплярів було віднесено до «невірних» кластерів, а який клас виявився «легким» для виділення;

- візуалізувати результати, використовуючи різні атрибути для осі ординат (при візуалізації екземпляри, позначені квадратами мають бути віднесені до «невірного» кластеру);

- визначити, на що впливає параметр «seed»;

- завантажити вибірку «flagdata.arff»;

- запустити алгоритм COBWEB з параметрами $C=0,4$ (0,35), `saveInstanceData = True`, `cluster mode = Use training set`;

- візуалізувати отриману дендрограму та вказати, що спільного у прапорів, які опинилися в одному кластері;

- завантажити вибірку «zoo.arff»;

- обрати з вибірки частину тварин на власний розсуд (за типом);

- запустити алгоритм Hierarchical Clusterer (тип тварини не використовувати в кластеризації, а назву за допомогою фільтру `NominalToString` перетворити на рядковий тип);

- візуалізувати результати роботи алгоритму та оцінити, чи є логічний сенс в створюваних кластерах;

- згенерувати вибірку за допомогою алгоритму BIRCHCluster. До вибірки згенерувати також флаг класу. Згенерований набір зберегти.

- за допомогою налаштувань методу DBSCAN досягнути найкращої кластеризації даних.

2. Вирішити задачу кластеризації за допомогою засобів мови програмування Python:

- конвертувати вибірку «vehicle.arff» в CSV формат, та завантажити в програму;

- виконати кластеризацію за допомогою алгоритму KMeans (кількість кластерів має дорівнювати кількості класів);

- продемонструвати та оцінити отримані результати;
 - конвертувати вибірку «zoo.arff» в CSV формат та завантажити в програму;
 - застосувати алгоритм ієрархічної кластеризації (при побудові матриці зв'язків видалити атрибути animal та type);
 - візуалізувати отримані результати (дендрограма);
 - конвертувати вибірку, яку було згенеровано за допомогою алгоритму BIRCHCluster у WEKA в CSV формат та завантажити;
 - виконати кластеризацію за допомогою алгоритму DBSCAN;
 - продемонструвати та оцінити отримані результати.
1. Відповісти на 5 контрольних запитань.
 2. Оформити звіт з роботи.

Виконання

1 Завантажити вибірку «bank.arff»

Вибірку завантажено [звідси](#). Результати на картинці нижче:




Рисунок 1.1 — Завантажена вибірка

2 Алгоритм кластеризації SimpleKMeans

Проведено тестування методом SimpleKMeans, кількість кластерів (numClusters) встановлено у значення 5:




Рисунок 2.1 — Метод SimpleKMeans в роботі

3 Таблиця значень сум квадратичних помилок, одержуваних при різних значеннях

Суми квадратичних помилок наведено нижче на таблиці:

Таблиця 3.1 — Суми квадратичних помилок при різних значеннях

Кількість кластерів	Значення суми
1	966.0427381179063
2	775.1756576878267
3	681.9387170881896
4	625.4296762510829
5	563.7995027565171
6	540.7387788014682
7	524.3484219577417
8	488.1650647851437
9	470.6564571657609
10	466.86014843503983
11	443.0877285538886
12	420.93289947544827

Чим більша кількість кластерів, тим менша помилка.

4 Візуалізувати результати кластеризації

Візуалізація надана на рисунку нижче:




Рисунок 4.1 — Вигляд кластерів

5 Описати скільки примірників потрапило в кожен із кластерів

Для кількості кластерів 5 знадобилося 4 ітерації. Для кожного в кластери потрапило:

1. 74
2. 68
3. 38
4. 80
5. 50

6 Таблиця з характеристиками центроїдів

Таблиця наведена нижче на рисунку:

Attribute	Cluster#					
	Full Data	0	1	2	3	4
	(300.0)	(74.0)	(68.0)	(38.0)	(70.0)	(50.0)
=====						
age	42.57	37.3243	42.8529	36.1842	47.9	47.34
sex	MALE	FEMALE	FEMALE	MALE	MALE	FEMALE
region	INNER_CITY	INNER_CITY	INNER_CITY	INNER_CITY	TOWN	TOWN
income	27655.4981	23988.2809	26995.7919	22453.4342	33871.2757	29231.66
married	YES	YES	NO	NO	YES	YES
children	YES	NO	YES	NO	YES	NO
car	NO	YES	NO	YES	YES	NO
mortgage	NO	NO	NO	YES	NO	YES
pep	NO	NO	YES	NO	YES	NO

Рисунок 6.1 — Вигляд таблиці центроїдів

7 Завантажити вибірку «iris.arff»

Вибірку завантажено, результати на рисунку нижче:




Рисунок 7.1 — Вигляд завантаженої вибірки

8 Алгоритм кластеризації SimpleKMeans з $K = 3$

Кластеризацію виконано добре, бо для кожного кластеру є по 50 екземплярів, як і для класів.

Вигляд результатів кластеризації видно нижче на рисунку:




Рисунок 8.1 — Вигляд результатів кластеризації

9 Записати характеристики кожного центроїду

Характеристика центроїдів наведена нижче на рисунку:

Final cluster centroids:				
Attribute	Cluster#			
	Full Data	0	1	2
	(150.0)	(50.0)	(50.0)	(50.0)
=====				
sepal.length	5.8433	5.936	5.006	6.588
sepal.width	3.054	2.77	3.418	2.974
petal.length	3.7587	4.26	1.464	5.552
petal.width	1.1987	1.326	0.244	2.026
class	Iris-setosa	Iris-versicolor	Iris-setosa	Iris-virginica

Рисунок 9.1 — Вигляд кластерних центроїдів

10 Описати як співвідносяться кластери та значення цільового атрибуту

При значенні кластерів 3, кожен кластер відповідає одному зі значень цільової ознаки.

11 Візуалізувати результати

Візуалізацію кластерів наведено на рисунку нижче:




Рисунок 11.1 — Візуалізація кластерів

12 Визначити, на що впливає параметр «seed»

Параметр seed впливає на випадковість розподілу.

13 Завантажити вибірку «flagdata.arff»

Вибірку завантажено. Деталі на рисунку нижче:




Рисунок 13.1 — Вигляд завантаженої вибірки

14 Алгоритм COBWEB

Параметри зазначено, кластеризацію виконано. Результати на картинці нижче:




Рисунок 14.1 — Вигляд результатів кластеризації

15 Візуалізувати отриману дендрограму

Вигляд візуалізації надано нижче на рисунку:




Рисунок 15.1 — Вигляд дерева

16 Завантажити вибірку «zoo.arff»

Вибірку завантажено, деталі на рисунку нижче:




Рисунок 16.1 — Вигляд завантаженої вибірки

17 Обрати з вибірки частину тварин

Вибрано зменшену кількість екземплярів фільтром Resample.
Деталі на картинці нижче:




Рисунок 17.1 — Вибрана вибірка

18 Алгоритм Hierarchical Clusterer

Зроблена модель Hierarchical Clusterer, деталі на рисунку нижче:




Рисунок 19.1 — Візуалізація ієрархічної кластеризації

20 Згенерувати вибірку за допомогою алгоритму BIRCHCluster

Для генерації флагу класу було встановлено значення classFlag у True. Згенерована вибірка визначена на картинці нижче:




Рисунок 20.1 — Згенерована вибірка

21 За допомогою налаштувань методу DBSCAN досягнути найкращої кластеризації даних

Для отримання доступу до алгоритму DBScan було встановлено модуль `optics_dbscan`, деталі на рисунку нижче:




Рисунок 21.1 — Встановлений модуль

Далі застосовано метод DBScan до вибірки даних.




Рисунок 21.2 — Використаний метод DBScan

ПИТАННЯ

Що таке задача кластеризації? Наведіть практичний приклад.

Задача кластеризації є розподілення вхідної вибірки на кластери — схожі між собою купки об'єктів.

Прикладом кластеризації є алгоритм К-найближчих сусідів.

Що таке навчання з учителем і без учителя? До якої стратегії відноситься задача кластеризації?

Навчання з учителем це коли у вибірці є вихідний параметр.

Навчання без учителя це коли вибірка містить лише вхідні параметри.

Кластеризація відноситься до навчання без учителя.

В чому схожість та відмінність задач класифікації та кластеризації?

Обидві розділяють вибірку на окремі купки об'єктів.

Кластеризація є навчанням без учителя.

Чим визначається «схожість» об'єктів при вирішенні задачі кластеризації?

Метрикою відстані, зазвичай Евклідової.

Які метрики застосовують для розрахунку відстані між екземплярами та кластерами?

Відомі метрики:

- Мангетенова відстань;
- Евклідова відстань.