

Міністерство освіти і науки України
Національний університет «Запорізька політехніка»

Кафедра програмних засобів

ЗВІТ

Дисципліна «Інтелектуальний аналіз даних»

Робота №6

Тема «Програмні засоби кластеризації даних»

Виконав варіант 19

Студент КНТ-122

Онищенко О.А.

Прийняли

Викладач

Андрєєв М.О.

2025

МЕТА

Метою роботи є ознайомитися та отримати навички роботи з програмою WEKA та бібліотеками мови програмування Python для вирішення задачі кластеризації. На практиці вивчити роботу алгоритмів кластеризації, навчитися інтерпретувати результати їх роботи та вибирати найкращий метод для розв'язуваної прикладної задач.

ЗАВДАННЯ

Завдання на роботу зі сторінки 35:

1. Вирішити задачу кластеризації за допомогою засобів мови програмування Python:

- конвертувати вибірку «vehicle.arff» в CSV формат, та завантажити в програму;
- виконати кластеризацію за допомогою алгоритму KMeans (кількість кластерів має дорівнювати кількості класів);
- продемонструвати та оцінити отримані результати;
- конвертувати вибірку «zoo.arff» в CSV формат та завантажити в програму;
- застосувати алгоритм ієрархічної кластеризації (при побудові матриці зв'язків видалити атрибути animal та type);
- візуалізувати отримані результати (дендрограма);
- конвертувати вибірку, яку було згенеровано за допомогою алгоритму BIRCHCluster у WEKA в CSV формат та завантажити;
- виконати кластеризацію за допомогою алгоритму DBSCAN;
- продемонструвати та оцінити отримані результати.

2. Відповісти на 5 контрольних запитань.

3. Оформити звіт з роботи.

ВИКОНАННЯ

Код імпортування модулів:

```
import os
import pandas as pd

from sklearn.model_selection import train_test_split
from sklearn.cluster import KMeans
from sklearn.metrics.cluster import contingency_matrix
```

KMeans

Код

```
current_dir = os.path.dirname(os.path.abspath(__file__))
file_name = "vehicle.csv"
file_path = os.path.join(current_dir, file_name)

df = pd.read_csv(file_path)
df = df.dropna()

TARGET_FEATURE = "Class"
Y = df[TARGET_FEATURE]
X = df.drop([TARGET_FEATURE], axis=1)
X_train, X_test, Y_train, Y_test = train_test_split(X, Y,
test_size=0.33)
print(X, Y)

KM = KMeans(n_clusters=len(Y_train))
KM.fit(X_train)

cluster_centers = pd.DataFrame(KM.cluster_centers_)
cluster_centers.columns = X.columns
print(cluster_centers)

Y_predict = KM.predict(X_test)
matrix = pd.DataFrame(contingency_matrix(Y_test, Y_predict))
matrix.index = Y.unique()
print(matrix)

right_cluster_count = 0
for column in matrix.columns:
    right_cluster_count += matrix[column].max()
accuracy = right_cluster_count / matrix.sum().sum()
error_rate = 1 - accuracy
```

```
print(f"{right_cluster_count=}")
print(f"{accuracy=}")
print(f"{error_rate=}")
```

Результат

```
COMPACTNESS  CIRCULARITY  DISTANCE  CIRCULARITY  ...  KURTOSIS  ABOUT_MAJOR  KURTOSIS  ABOUT_MINOR  HOLLOWES  RATIO
0            98.0         51.0           84.0  ...           11.0           196.0         199.0
1            88.0         42.0           77.0  ...           11.0           198.0         205.0
2           107.0         56.0          105.0  ...            1.0           189.0         196.0
3           110.0         58.0          106.0  ...           13.0           181.0         182.0
4            92.0         46.0           82.0  ...           11.0           200.0         208.0
..          ...         ...           ...  ...          ...           ...           ...
561           97.0         46.0          101.0  ...           32.0           191.0         200.0
562           86.0         42.0           64.0  ...            3.0           179.0         182.0
563           89.0         36.0           77.0  ...           22.0           198.0         205.0
564           87.0         36.0           53.0  ...           15.0           180.0         183.0
565           86.0         43.0           70.0  ...            9.0           179.0         182.0

[566 rows x 18 columns]
```

	0	1	2	3	4	5	6	7	8	9	10	...	203	204	205	206	207	208	209	210	211	212	213
van	1	0	1	1	1	0	2	0	1	1	0	...	2	0	0	1	1	1	0	1	0	1	0
saab	0	1	0	0	0	1	0	0	1	0	2	...	0	2	1	0	0	0	1	0	0	0	0
bus	0	0	0	0	0	0	0	0	1	0	0	...	0	0	0	0	0	0	0	0	0	0	0
opel	0	0	0	0	0	1	0	1	0	0	0	...	0	0	0	0	0	0	0	0	2	0	1

```

[4 rows x 214 columns]
right_cluster_count=np.int64(255)
accuracy=np.float64(0.9107142857142857)
error_rate=np.float64(0.0892857142857143)
```

Рисунок 1.1 — Результати роботи KMeans

Метод DBSCAN

Код

```
import os
import pandas as pd
import numpy as np

from sklearn.model_selection import train_test_split
from sklearn.metrics.cluster import contingency_matrix
from sklearn.cluster import DBSCAN

current_dir = os.path.dirname(os.path.abspath(__file__))
file_name = "zoo.csv"
file_path = os.path.join(current_dir, file_name)

df = pd.read_csv(file_path)
TARGET_FEATURE = "type"
Y = df[TARGET_FEATURE]
X = df.drop([TARGET_FEATURE, "animal"], axis=1)
print(X)

model = DBSCAN(eps=0.5, min_samples=5)
Y_predict = model.fit_predict(X)
```

```
matrix = pd.DataFrame(contingency_matrix(Y, Y_predict))
matrix.index = Y.unique()
matrix.columns = np.unique(Y_predict)
print(matrix)
```

Результати

	hair	feathers	eggs	milk	airborne	aquatic	...	venomous	fins	legs	tail	domestic	catsize
0	True	False	False	True	False	False	...	False	False	4	False	False	True
1	True	False	False	True	False	False	...	False	False	4	True	False	True
2	False	False	True	False	False	True	...	False	True	0	True	False	False
3	True	False	False	True	False	False	...	False	False	4	False	False	True
4	True	False	False	True	False	False	...	False	False	4	True	False	True
..	...	...	...	...	...	...	...	...	...	...	...	...	...
96	True	False	False	True	False	False	...	False	False	2	True	False	True
97	True	False	True	False	True	False	...	True	False	6	False	False	False
98	True	False	False	True	False	False	...	False	False	4	True	False	True
99	False	False	True	False	False	False	...	False	False	0	False	False	False
100	False	True	True	False	True	False	...	False	False	2	True	False	False

[101 rows x 16 columns]

	-1	0	1	2
mammal	4	0	0	0
fish	20	0	0	0
bird	8	0	5	0
invertebrate	8	0	0	0
insect	10	0	0	0
amphibian	25	6	0	10
reptile	5	0	0	0

Рисунок 2.1 — Результати виконання

Ієрархічна кластеризація

Код

```
import os
import pandas as pd
from matplotlib import pyplot as plt

from scipy.cluster.hierarchy import linkage, dendrogram

current_dir = os.path.dirname(os.path.abspath(__file__))
file_name = "zoo.csv"
file_path = os.path.join(current_dir, file_name)

df = pd.read_csv(file_path)
TARGET_FEATURE = "type"
Y = df[TARGET_FEATURE]
X = df.drop([TARGET_FEATURE, "animal"], axis=1)
print(X)

mergins = linkage(X, method="complete")
dendrogram(mergins, labels=Y.tolist())
```

```
plt.show()
```

Результати




Рисунок 3.1 — Дендрограма, отримана в результаті роботи

Питання

Що таке задача кластеризації? Наведіть практичний приклад.

Задача кластеризації є розподілення вхідної вибірки на кластери — схожі між собою купки об'єктів.

Прикладом кластеризації є алгоритм К-найближчих сусідів.

Що таке навчання з учителем і без учителя? До якої стратегії відноситься задача кластеризації?

Навчання з учителем це коли у вибірці є вихідний параметр.

Навчання без учителя це коли вибірка містить лише вхідні параметри.

Кластеризація відноситься до навчання без учителя.

В чому схожість та відмінність задач класифікації та кластеризації?

Обидві розділяють вибірку на окремі купки об'єктів.

Кластеризація є навчанням без учителя.

Чим визначається «схожість» об'єктів при вирішенні задачі кластеризації?

Метрикою відстані, зазвичай Евклідової.

Які метрики застосовують для розрахунку відстані між екземплярами та кластерами?

Відомі метрики:

- Мангетенова відстань;
- Евклідова відстань.