

**Міністерство освіти і науки України**  
**Національний університет «Запорізька політехніка»**

Кафедра програмних засобів

**ЗВІТ**

Дисципліна «Інтелектуальний аналіз даних»

Робота №6

Тема «Програмні засоби кластеризації даних»

**Виконав варіант 19**

Студент КНТ-122

Онищенко О.А.

**Прийняли**

Викладач

Андрєєв М.О.

2025

## МЕТА

Метою роботи є ознайомитися та отримати навички роботи з програмою WEKA та бібліотеками мови програмування Python для вирішення задачі кластеризації. На практиці вивчити роботу алгоритмів кластеризації, навчитися інтерпретувати результати їх роботи та вибирати найкращий метод для розв'язуваної прикладної задач.

## ЗАВДАННЯ

Завдання на роботу зі сторінки 35:

1. Вирішити задачу кластеризації за допомогою програми WEKA завантажити вибірку «bank.arff»;

- запустити алгоритм кластеризації SimpleKMeans, задаючи значення параметра K (кількість кластерів) від 1 до 12;

- записати в таблицю значення сум квадратичних помилок, одержуваних при різних значеннях. Проаналізувати результат;

- для значення  $K = 5$  візуалізувати результати кластеризації (по осі абсцис відкласти назву (номер) кластера, по осі ординат – номер примірника в кластері);

- описати скільки примірників потрапило в кожен із кластерів, скільки ітерацій знадобилося для кластеризації даних;

- скласти таблицю з характеристиками центроїдів;

- завантажити вибірку «iris.arff»;

- запустити алгоритм кластеризації SimpleKMeans з  $K = 3$  та оцінити якість кластеризації, порівнюючи кластери з попередньо заданими класами;

- записати характеристики кожного центроїду;

- описати як співвідносяться кластери та значення цільового атрибуту, скільки екземплярів було віднесено до «невірних» кластерів, а який клас виявився «легким» для виділення;

- візуалізувати результати, використовуючи різні атрибути для осі ординат (при візуалізації екземпляри, позначені квадратами мають бути віднесені до «невірного» кластеру);

- визначити, на що впливає параметр «seed»;

- завантажити вибірку «flagdata.arff»;

- запустити алгоритм COBWEB з параметрами  $C=0,4$  (0,35), `saveInstanceData = True`, `cluster mode = Use training set`;

- візуалізувати отриману дендрограму та вказати, що спільного у прапорів, які опинилися в одному кластері;

- завантажити вибірку «zoo.arff»;

- обрати з вибірки частину тварин на власний розсуд (за типом);

- запустити алгоритм Hierarchical Clusterer (тип тварини не використовувати в кластеризації, а назву за допомогою фільтру `NominalToString` перетворити на рядковий тип);

- візуалізувати результати роботи алгоритму та оцінити, чи є логічний сенс в створюваних кластерах;

- згенерувати вибірку за допомогою алгоритму BIRCHCluster. До вибірки згенерувати також флаг класу. Згенерований набір зберегти.

- за допомогою налаштувань методу DBSCAN досягнути найкращої кластеризації даних.

2. Вирішити задачу кластеризації за допомогою засобів мови програмування Python:

- конвертувати вибірку «vehicle.arff» в CSV формат, та завантажити в програму;

- виконати кластеризацію за допомогою алгоритму KMeans (кількість кластерів має дорівнювати кількості класів);

- продемонструвати та оцінити отримані результати;
  - конвертувати вибірку «zoo.arff» в CSV формат та завантажити в програму;
  - застосувати алгоритм ієрархічної кластеризації (при побудові матриці зв'язків видалити атрибути animal та type);
  - візуалізувати отримані результати (дендрограма);
  - конвертувати вибірку, яку було згенеровано за допомогою алгоритму BIRCHCluster у WEKA в CSV формат та завантажити;
  - виконати кластеризацію за допомогою алгоритму DBSCAN;
  - продемонструвати та оцінити отримані результати.
1. Відповісти на 5 контрольних запитань.
  2. Оформити звіт з роботи.

## **Виконання**

### **1 Завантажити вибірку «bank.arff»**

Вибірку завантажено [звідси](#). Результати на картинці нижче:




Рисунок 1.1 — Завантажена вибірка

## 2 Алгоритм кластеризації SimpleKMeans

Проведено тестування методом SimpleKMeans, кількість кластерів (numClusters) встановлено у значення 5:




Рисунок 2.1 — Метод SimpleKMeans в роботі

### 3 Таблиця значень сум квадратичних помилок, одержуваних при різних значеннях

Суми квадратичних помилок наведено нижче на таблиці:

Таблиця 3.1 — Суми квадратичних помилок при різних значеннях

| Кількість кластерів | Значення суми      |
|---------------------|--------------------|
| 1                   | 966.0427381179063  |
| 2                   | 775.1756576878267  |
| 3                   | 681.9387170881896  |
| 4                   | 625.4296762510829  |
| 5                   | 563.7995027565171  |
| 6                   | 540.7387788014682  |
| 7                   | 524.3484219577417  |
| 8                   | 488.1650647851437  |
| 9                   | 470.6564571657609  |
| 10                  | 466.86014843503983 |
| 11                  | 443.0877285538886  |
| 12                  | 420.93289947544827 |

Чим більша кількість кластерів, тим менша помилка.

#### 4 Візуалізувати результати кластеризації

Візуалізація надана на рисунку нижче:




Рисунок 4.1 — Вигляд кластерів

## 5 Описати скільки примірників потрапило в кожен із кластерів

Для кількості кластерів 5 знадобилося 4 ітерації. Для кожного в кластери потрапило:

1. 74
2. 68
3. 38
4. 80
5. 50

## 6 Таблиця з характеристиками центроїдів

Таблиця наведена нижче на рисунку:

| Attribute | Cluster#   |            |            |            |            |          |
|-----------|------------|------------|------------|------------|------------|----------|
|           | Full Data  | 0          | 1          | 2          | 3          | 4        |
|           | (300.0)    | (74.0)     | (68.0)     | (38.0)     | (70.0)     | (50.0)   |
| =====     |            |            |            |            |            |          |
| age       | 42.57      | 37.3243    | 42.8529    | 36.1842    | 47.9       | 47.34    |
| sex       | MALE       | FEMALE     | FEMALE     | MALE       | MALE       | FEMALE   |
| region    | INNER_CITY | INNER_CITY | INNER_CITY | INNER_CITY | TOWN       | TOWN     |
| income    | 27655.4981 | 23988.2809 | 26995.7919 | 22453.4342 | 33871.2757 | 29231.66 |
| married   | YES        | YES        | NO         | NO         | YES        | YES      |
| children  | YES        | NO         | YES        | NO         | YES        | NO       |
| car       | NO         | YES        | NO         | YES        | YES        | NO       |
| mortgage  | NO         | NO         | NO         | YES        | NO         | YES      |
| pep       | NO         | NO         | YES        | NO         | YES        | NO       |

Рисунок 6.1 — Вигляд таблиці центроїдів

## 7 Завантажити вибірку «iris.arff»

Вибірку завантажено, результати на рисунку нижче:




Рисунок 7.1 — Вигляд завантаженої вибірки

## 8 Алгоритм кластеризації SimpleKMeans з $K = 3$

Кластеризацію виконано добре, бо для кожного кластеру є по 50 екземплярів, як і для класів.

Вигляд результатів кластеризації видно нижче на рисунку:




Рисунок 8.1 — Вигляд результатів кластеризації

## 9 Записати характеристики кожного центроїду

Характеристика центроїдів наведена нижче на рисунку:

| Final cluster centroids: |             |                 |             |                |
|--------------------------|-------------|-----------------|-------------|----------------|
| Attribute                | Cluster#    |                 |             |                |
|                          | Full Data   | 0               | 1           | 2              |
|                          | (150.0)     | (50.0)          | (50.0)      | (50.0)         |
| =====                    |             |                 |             |                |
| sepal.length             | 5.8433      | 5.936           | 5.006       | 6.588          |
| sepal.width              | 3.054       | 2.77            | 3.418       | 2.974          |
| petal.length             | 3.7587      | 4.26            | 1.464       | 5.552          |
| petal.width              | 1.1987      | 1.326           | 0.244       | 2.026          |
| class                    | Iris-setosa | Iris-versicolor | Iris-setosa | Iris-virginica |

Рисунок 9.1 — Вигляд кластерних центроїдів

## 10 Описати як співвідносяться кластери та значення цільового атрибуту

При значенні кластерів 3, кожен кластер відповідає одному зі значень цільової ознаки.

## 11 Візуалізувати результати

Візуалізацію кластерів наведено на рисунку нижче:




Рисунок 11.1 — Візуалізація кластерів

## 12 Визначити, на що впливає параметр «seed»

Параметр seed впливає на випадковість розподілу.

## 13 Завантажити вибірку «flagdata.arff»

Вибірку завантажено. Деталі на рисунку нижче:




Рисунок 13.1 — Вигляд завантаженої вибірки

## 14 Алгоритм COBWEB

Параметри зазначено, кластеризацію виконано. Результати на картинці нижче:




Рисунок 14.1 — Вигляд результатів кластеризації

## 15 Візуалізувати отриману дендрограму

Вигляд візуалізації надано нижче на рисунку:




Рисунок 15.1 — Вигляд дерева

## 16 Завантажити вибірку «zoo.arff»

Вибірку завантажено, деталі на рисунку нижче:




Рисунок 16.1 — Вигляд завантаженої вибірки

## 17 Обрати з вибірки частину тварин

Вибрано зменшену кількість екземплярів фільтром Resample.  
Деталі на картинці нижче:




Рисунок 17.1 — Вибрана вибірка

## 18 Алгоритм Hierarchical Clusterer

Зроблена модель Hierarchical Clusterer, деталі на рисунку нижче:






Рисунок 19.1 — Візуалізація ієрархічної кластеризації

## 20 Згенерувати вибірку за допомогою алгоритму BIRCHCluster

Для генерації флагу класу було встановлено значення `classFlag` у `True`. Згенерована вибірка визначена на картинці нижче:




Рисунок 20.1 — Згенерована вибірка

## 21 За допомогою налаштувань методу DBSCAN досягнути найкращої кластеризації даних

Для отримання доступу до алгоритму DBScan було встановлено модуль `optics_dbscan`, деталі на рисунку нижче:




Рисунок 21.1 — Встановлений модуль

Далі застосовано метод DBScan до вибірки даних.




Рисунок 21.2 — Використаний метод DBScan

## Висновки

Благодаттю Господа Ісуса Христа було зроблено роботу.

## Питання

**Що таке задача кластеризації? Наведіть практичний приклад.**

Задача кластеризації є розподілення вхідної вибірки на кластери — схожі між собою купки об'єктів.

Прикладом кластеризації є алгоритм К-найближчих сусідів.

**Що таке навчання з учителем і без учителя? До якої стратегії відноситься задача кластеризації?**

Навчання з учителем це коли у вибірці є вихідний параметр.

Навчання без учителя це коли вибірка містить лише вхідні параметри.

Кластеризація відноситься до навчання без учителя.

**В чому схожість та відмінність задач класифікації та кластеризації?**

Обидві розділяють вибірку на окремі купки об'єктів.

Кластеризація є навчанням без учителя.

**Чим визначається «схожість» об'єктів при вирішенні задачі кластеризації?**

Метрикою відстані, зазвичай Евклідової.

**Які метрики застосовують для розрахунку відстані між екземплярами та кластерами?**

Відомі метрики:

- Мангетенова відстань;
- Евклідова відстань.